

Open in app ↗

≡ Medium



Hipotez Testlerinde Pingouin Kullanımı: Veri Analizi ve Python

5 min read · Jan 10, 2023



Emrean Ulu

Follow



Share



More

Pingouin kullanımına yönelik hazırladığım bu veri analizi içeriğinde Python ile temel iki hipotez fonksiyonunu tanıtacağım.

Hipotez testi, bir hipotezi çürütmeye çalışarak geçerliliğini değerlendirmek için kullanılan istatistiksel bir yöntemdir. Topladığımız veriler hakkında karar vermemize ve bunlarla ilgili sonuçlar çıkarmamıza izin verdiği için istatistiksel analizin önemli bir parçasıdır. Özellikle İstatistik, İktisat, Ekonometri ve benzeri matematiksel analiz metotlarına dayanan bölümlerde birçok öğrencinin bölüm projelerinden hipotez testleri de sıklıkta istenmektedir.

Hipotez Testi, Python ve Veri Analizi

Pingouin, Python'da istatistiksel analiz için hazırlanmış bir kütüphanedir.

Biliyorsunuz ki Python'da gerek Pandas ve gerekse NumPy gibi veri setleri üzerine hazırlanmış olan ve veri analizi metotlarının temellerini oluşturan birçok kütüphane mevcut. Pingouin ise bu noktada hipotez testlerini ve diğer istatistiksel testleri hızlı, kolay bir şekilde gerçekleştirmek için mükemmel bir araç olarak kaşımıza çıkıyor. Bu yazımda sizlere iki temel hipotez testi türü üzerinden veri analizi gerçekleştireceğim. Kendi hipotez örneklemelerinize yararlı olmasını ve işinizi kolaylaştırmasını diliyorum.

pingouin

Python ile Pingouin

T-Testleri ve ANOVA

Bu yazımda işleyeceğim konu T-testleri ve ANOVA üzerinden olacak.

T-testleri, iki grubun ortalamalarını karşılaştırmak için kullanılır. Örneğin iki grubun ortalamaları arasında fark olup olmadığını belirlemek için kullanabiliriz.

ANOVA veya varyans analizi ise ikiden fazla grubun ortalamalarını karşılaştırmak için kullanılmaktadır. Bu yazımızda ikiden fazla grupların ortalamaları arasında anlamlı bir fark olup olmadığını belirlemek için ANOVA'yı kullanacağız. Python ile bu işin son derece kolaylaştığını da göreceksiniz.



Veri Analizi konusunda T-Test Tipleri

Pingouin ile T-Testi

Bağımsız T-testimiz için “**Erkeklerin ve kadınların boyları arasında anlamlı bir fark yoktur.**” şeklinde bir hipotez oluşturuyorum. 100 erkek ve 100 kadının boyuna sahip bir veri seti oluşturarak işe başlayacağız.

```
import pandas as pd
import pingouin as pg
import numpy as np
np.random.seed(42)
# Erkekler için
men_height = np.random.normal(loc=178, scale=8, size=100)
# Kadınlar için
women_height = np.random.normal(loc=162, scale=6, size=100)
# Pandas olarak alıyorum
df = pd.DataFrame({'Gender': ['Male'] * 100 + ['Female'] * 100, 'Height': np
print(df)
```

	Gender	Height
0	Male	181.973713
1	Male	176.893886
2	Male	183.181508
3	Male	190.184239
4	Male	176.126773
..	...	...
195	Female	164.311904
196	Female	156.696855
197	Female	162.922351
198	Female	162.349252
199	Female	155.142178

[200 rows x 2 columns]

Görüştüğümüz üzere Python Pandas ile veri setine dönüştürdüğüm ve NumPy kullanarak oluşturmuş olduğum yüzer adet erkek ve kadın boyları var. Erkek boylarında 178'i ve kadın boylarında ise 162'yi ortalama olarak belirledim, zira bunu yapmasaydım muhtemelen geniş aralıklı bir boy ortalaması olacaktı ve bu durum gerçekliğe yakın olmayacaktı. Python kullanımına devam ediyoruz.

```
male = df.query('Gender == "Male"')['Height']
female = df.query('Gender == "Female"')['Height']
t_test_results = pg.ttest(male, female, correction=False)
```

Burada correction komutunu False giriyorum zira vermiş olduğum veri setinde

düzeltilmeyi gerektirecek herhangi bir durum söz konusu değil. Ciddi manada büyük veri seti vermeniz durumunda Pingouin sizin için bu düzeltmeyi yapabiliyor. Aynı zamanda yapmış olduğum ikili grup Pandas düzeltmesine de dikkat edin.

```
T          15.616276
dof         198
alternative two-sided
p-val        0.0
CI95%      [13.87, 17.88]
cohen-d      2.208475
BF10        7.34e+32
power        1.0
dtype: object
```

İstatistikte t-testleri kullanılırken genellikle alfa değeri 0.05 olarak kabul edilmektedir. Alfa değeri ise bizim t-testimizin sonuçlarından olan p değerimizi karşılaştıracığımız bir indikatördür, bir nevi turnusol kağıdı gibi bile düşünebilirsiniz. Sonuçlardan görebileceğiniz üzere p değerimiz 0.0 olarak gözüküyor ki bu da aslında 0.00001 gibi bir değere tekabül etmektedir.


Alfa < p değeri olumlu,

Alfa > p değeri olumsuz anlam içerir.

P değerinin alfadan uzaklığı ise anlamın kuvvetini söyler. Bizim örneğimizde 0.00001 olan p değerimiz son derece kuvvetlidir.

Hatırlayalım, hipotezimiz “erkeklerin ve kadınların boyları arasında anlamlı bir fark yoktur” şeklindeydi. **Bu durumda p değerimiz alfadan ciddi manada küçük olduğu için hipotezimizi reddederiz.** Yani, gerek genetik ve gerekse çevresel faktörlerle oluşması muhtemel olarak, **kadınlar ve erkekler arasında ciddi bir boy farkı söz konusu.**

Ufak bir ek bilgi olarak Python çıktısında görebileceğiniz cohen-d değerimizin 2.20 olması da aslında verdiğimiz iki grup arasındaki ortalamanın ciddi bir farkını da bize işaret ediyor, bu değer istatistiksel açıdan yorumumuzu anlamlı kılmakta.



ANOVA tipleri ve Hipotez Testi

Pingouin ile ANOVA Testi

Bu sefer uygulayacağımız Pingouin ile ANOVA testi için “Farklı ülkelerde bulunan insanların boylarında ciddi bir fark yoktur.” şeklinde hipotez oluşturuyorum. Bunun için Python ile görece anlamlı bir veri seti oluşturarak veri analizi işine koyulacağım.

```
import pandas as pd
import pingouin as pg
import numpy as np
np.random.seed(42)
# USA
usa_men_heights = np.random.normal(loc=178, scale=7, size=100)
usa_women_heights = np.random.normal(loc=164, scale=6, size=100)
# Turkey
turkey_men_heights = np.random.normal(loc=173, scale=6, size=100)
turkey_women_heights = np.random.normal(loc=162, scale=5, size=100)
# China
china_men_heights = np.random.normal(loc=175, scale=5, size=100)
china_women_heights = np.random.normal(loc=162, scale=4, size=100)
# Germany
germany_men_heights = np.random.normal(loc=178, scale=7, size=100)
germany_women_heights = np.random.normal(loc=164, scale=6, size=100)
# Pandas olarak alıyorum
df = pd.DataFrame({'Country': ['USA'] * 200 + ['Turkey'] * 200 + ['China'] * 200 + ['Germany'] * 200,
                   'Height': [usa_men_heights, usa_women_heights, turkey_men_heights, turkey_women_heights, china_men_heights, china_women_heights, germany_men_heights, germany_women_heights]})
print(df)
```

	Country	Height
0	USA	184.567987
1	USA	174.387687

```
2      USA  178.672845
3      USA  174.764073
4      USA  174.958526
...    ...
795   Germany  157.941616
796   Germany  167.714926
797   Germany  176.344973
798   Germany  164.124762
799   Germany  159.631982
[800 rows x 2 columns]
```

Yeniden NumPy kullanarak oluşturduğum Pandas veri setinde erkek ve kadın boylarını ayırmayı ihmal etmedim. Ülkelere göre ayırdığım Python veri setinde belirlediğim ortalama ve standart sapma oranları internetten almış olduğum değerlere dayanıyor, amacım ise gerçeğe uygunluk. Şimdi yeniden Pingouin kullanımına geçiyoruz.

```
ANOVA_test_results = pg.anova(data=df, dv='Height', between='Country')
```

Tek yapmam gereken Python ile veri setini belirtmek, verilerin konumunu belirtmek ve nasıl gruplayacağını söylemek. Çıkan veri analizi sonuçları ise şu şekilde:

Source	Country
ddof1	3
ddof2	796
F	7.231818
p-unc	0.000086
np2	0.026532

Açıkça görüldüğü üzere p değerimiz genel geçer kabullü alfa değerimiz olan 0.05'ten küçük.

Alfa < p değeri olumlu,


Alfa > p değeri olumsuz anlam içerir.

P değerinin alfadan uzaklığı ise anlamın kuvvetini söyler. Bizim örneğimizde

0.000086 değeri kuvvetli bir anlamdır.

Alfa değeri p'den yüksek olduğu için hipotezimi reddetmem ve ülkeler arasında ciddi bir boy farkı olduğunu veri analizi açısından söylemem mümkün. Bu boy farkının genetik ve çevresel faktörlere göre değişebileceğini de yeniden belirtmekte yarar var.

Ek olarak veri analizi ile, ortalama değerler arasındaki farkın anlamlı olduğunu gösteren yüksek bir F-değerine sahip olduğum da (7.23) görülmektedir. Etkili büyüklük yarım eta-karesi (η^2) ile temsil edilmektedir ve aslında 0.03 de oldukça yüksektir. Bu istatistikler veri analizi sonuçlarımızı doğrular niteliktedir.



Veri Analizi

Veri Analizi ile Pingouin Kullanımı

Sonuç olarak hipotez testi, verilerimiz hakkında sonuçlar çıkarmamızı sağlayan istatistiksel analizin çok önemli bir yönüdür. Pingouin, Python'da çeşitli testleri

hızlı ve kolay bir şekilde gerçekleştirmeyi kolaylaştıran kullanışlı bir kitaplıktır. Verdiğim örneklerde görebileceğiniz üzere iki grubun araçlarını karşılaştırmak için t-testlerini ve ikiden fazla grubun araçlarını karşılaştırmak için ANOVA'yı kullanabiliriz. Yukarıdaki örnekleri takip ederek bu testleri kolayca yapabilir ve veri analizi işlerinizi kolaylıkla Pingouin ile gerçekleştirebilirsiniz.

Ekler:

<https://www.marsja.se/three-ways-to-carry-out-2-way-anova-with-python/>

<https://www.marsja.se/how-to-perform-a-two-sample-t-test-with-python-3-different-methods/>

<https://vitalflux.com/one-way-anova-test-concepts-formula-examples/>

<https://online.stat.psu.edu/stat200/lesson/9/9.2/9.2.2/9.2.2.1/9.2.2.1.3>

Veri Bilimi

Veri Analitiği

Veri

Türkçe

Pingouin



Follow

Written by Emre Can Ulu

0 followers · 1 following

krypton'un oğlu, gotham'ın yarasası

No responses yet



Mehmet Pekmezci

What are your thoughts?

